

Universidad Católica del Maule

Facultad de Ciencias Básicas

Carrera de Ingeniería Estadística

Clasificación de pobreza por ingresos en hogares chilenos mediante modelos supervisados de aprendizaje automático

Proyecto Final de Data Mining

Integrantes:

Francisca Aravena Garrido

Martín Elizondo Norambuena

Krishna Rojas Rojas

Docente: Rodrigo Rivera

Curso: Data Mining

Fecha: Julio 2026

Índice

1. Introducción	4
2. Planteamiento del problema y objetivos	5
2.1. Pregunta de investigación	5
2.2. Objetivo general	5
2.3. Objetivos específicos	5
3. Base de datos y selección de variables	5
3.1. Fuente de información, unidad de análisis y variable objetivo	5
3.2. Selección de variables predictoras	6
3.3. Variables excluidas para evitar filtración de información	7
4. Preparación y limpieza de datos	7
5. Análisis exploratorio de datos	7
5.1. Distribución de la pobreza por ingresos	8
5.2. Variables numéricas según pobreza	8
5.3. Variables laborales y de formalidad	9
5.4. Variables educacionales y composición del hogar	10
5.5. Variables territoriales y habitacionales	11
5.6. Asociaciones bivariadas	12
5.7. Síntesis del análisis exploratorio	13
6. Metodología de modelamiento	14
6.1. Tipo de problema	14
6.2. Partición de datos	14
6.3. Preprocesamiento	15
6.4. Métricas de evaluación	15
6.5. Validación cruzada y ajuste de hiperparámetros	16
7. Modelos utilizados	16
7.1. Regresión logística completa	16
7.2. Regresión logística parsimoniosa	16
7.3. Árbol de decisión	17
7.4. Random Forest ajustado	17
8. Resultados	18
8.1. Comparación final de modelos	18
8.2. Matriz de confusión del modelo final	18
8.3. Curvas ROC y Precision-Recall	19
9. Importancia de variables del modelo final	20
10. Conclusiones	22
A. Variables utilizadas	25
B. Árbol de decisión	25

C. Tabla completa de importancia de variables	27
D. Notebook y reproducibilidad	28
E. Coeficientes y odds ratios de la regresión logística	28

Resumen

El presente trabajo tuvo como objetivo clasificar la condición de pobreza por ingresos en hogares chilenos utilizando datos de la Encuesta CASEN 2024 y modelos supervisados de aprendizaje automático. Para ello, se construyó una base final a nivel de hogares, considerando como unidad de análisis a la jefatura del hogar, y se definió una variable objetivo binaria que distingue entre hogares en pobreza y hogares fuera de pobreza.

Con el fin de evitar filtración de información o *data leakage*, se excluyeron variables directamente relacionadas con ingresos, deciles, quintiles y líneas de pobreza. Posteriormente, se ajustaron y compararon distintos modelos de clasificación: regresión logística balanceada completa, regresión logística parsimoniosa extendida, árbol de decisión y Random Forest ajustado.

Los resultados mostraron que el Random Forest ajustado obtuvo el mejor desempeño predictivo, con un F1-score de 0,582, ROC-AUC de 0,863 y PR-AUC de 0,617. Además, presentó un recall de 0,813, lo que indica una buena capacidad para identificar hogares en pobreza. Por su parte, la regresión logística balanceada completa fue útil como modelo interpretable, ya que permitió analizar la dirección de las asociaciones mediante coeficientes y *odds ratios*.

Las variables más relevantes para la clasificación fueron principalmente la tasa de ocupados del hogar, la cotización previsional, el contrato laboral, la edad, la escolaridad y la condición de actividad. En conjunto, los resultados sugieren que las dimensiones laborales, de formalidad, educacionales y de composición del hogar aportan información importante para clasificar la pobreza por ingresos. Finalmente, se destaca que los resultados corresponden a asociaciones predictivas y no deben interpretarse como relaciones causales.

1. Introducción

La pobreza por ingresos es una problemática social relevante, ya que refleja la insuficiencia de recursos económicos de los hogares para satisfacer un conjunto de necesidades básicas. Su estudio resulta importante no solo para describir la situación socioeconómica de la población, sino también para identificar características asociadas a mayores niveles de vulnerabilidad. En Chile, una de las principales fuentes de información para analizar este fenómeno es la Encuesta de Caracterización Socioeconómica Nacional (CASEN), la cual entrega información sobre ingresos, educación, trabajo, vivienda, salud, composición del hogar y otras dimensiones sociales [1]. Generalmente, la pobreza por ingresos se mide a partir de la comparación entre los ingresos del hogar y una línea de pobreza definida metodológicamente [2].

Sin embargo, desde una perspectiva de Data Mining, también resulta de interés estudiar si es posible clasificar la condición de pobreza utilizando características observables de los hogares que no correspondan directamente a ingresos, deciles, quintiles o líneas de pobreza. Esta decisión responde a la necesidad de evitar filtración de información o *data leakage*, problema que ocurre cuando el modelo utiliza información que no debería estar disponible al momento de predecir, generando evaluaciones artificialmente optimistas del desempeño [3, 4]. Al excluir variables directamente derivadas del ingreso, el análisis permite explorar patrones asociados a la pobreza desde dimensiones laborales, educacionales, habitacionales, territoriales y de composición del hogar, las cuales son relevantes para caracterizar las condiciones socioeconómicas de los hogares [1, 5].

Diversos estudios han mostrado que la pobreza se relaciona con factores como la inserción laboral, la escolaridad, la composición familiar y las condiciones materiales de vida [6, 7]. En este sentido, el uso de técnicas supervisadas de clasificación puede aportar una mirada complementaria al análisis socioeconómico tradicional, permitiendo comparar modelos interpretables y modelos con mayor capacidad predictiva. Este enfoque no busca reemplazar la medición oficial de pobreza, sino analizar qué características de los hogares permiten distinguir entre hogares en pobreza y hogares fuera de pobreza dentro de la base CASEN 2024.

En este trabajo se construye una base de datos a nivel de hogares, considerando como unidad de análisis a la jefatura del hogar. A partir de la variable original de pobreza se define una variable objetivo binaria, denominada **pobreza_ingresos**, que toma el valor 1 si el hogar se encuentra en pobreza extrema o pobreza no extrema, y el valor 0 si se encuentra fuera de pobreza. Esta recodificación se justifica porque el objetivo del estudio es clasificar la presencia o ausencia de pobreza por ingresos en el hogar, agrupando las categorías de pobreza extrema y pobreza no extrema en una sola clase positiva, en coherencia con la medición oficial de pobreza por ingresos [2].

Posteriormente, se ajustan y comparan distintos modelos supervisados de clasificación: regresión logística, árbol de decisión y Random Forest. La regresión logística se utiliza como modelo interpretable, debido a que permite analizar la dirección de las asociaciones mediante coeficientes y odds ratios [8]. En cambio, los modelos basados en árboles permiten representar reglas de decisión y capturar relaciones no lineales entre variables [9]. En particular, Random Forest se considera una alternativa predictiva más robusta, ya que combina múltiples árboles de decisión y promedia sus resultados, lo que puede mejorar la precisión predictiva y reducir problemas de sobreajuste respecto de un árbol individual [10, 11]. De esta forma, el trabajo busca equilibrar dos objetivos: obtener un modelo con buen desempeño predictivo y, al mismo tiempo mantener una interpretación sustantiva de los principales factores asociados a la clasificación de pobreza por ingresos.

2. Planteamiento del problema y objetivos

A partir del contexto presentado, este trabajo aborda un problema de clasificación supervisada aplicado a la pobreza por ingresos en hogares chilenos. En particular, se busca analizar si ciertas características observables de los hogares permiten distinguir entre aquellos que se encuentran en situación de pobreza por ingresos y aquellos que se encuentran fuera de pobreza, utilizando información de la encuesta CASEN 2024. El problema se plantea considerando que la pobreza por ingresos es medida oficialmente a partir de variables directamente asociadas al ingreso del hogar. Sin embargo, para efectos del modelamiento predictivo, dichas variables no son utilizadas como predictoras, con el fin de evitar filtración de información. De esta manera, el análisis se centra en variables sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar.

2.1. Pregunta de investigación

¿Qué características de los hogares permiten clasificar la condición de pobreza por ingresos en Chile según la Encuesta CASEN 2024?

2.2. Objetivo general

Clasificar la condición de pobreza por ingresos de los hogares chilenos a partir de variables sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar de la Encuesta CASEN 2024, mediante modelos supervisados de clasificación.

2.3. Objetivos específicos

- Preparar una base de datos a nivel de hogares a partir de la Encuesta CASEN 2024, construyendo una variable objetivo binaria que identifique la condición de pobreza por ingresos.
- Seleccionar y justificar variables predictoras sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar, considerando literatura, criterios metodológicos y análisis exploratorio.
- Ajustar modelos supervisados de clasificación para predecir la condición de pobreza por ingresos de los hogares.
- Comparar el desempeño predictivo de los modelos e identificar las variables más relevantes para la clasificación de hogares en pobreza por ingresos.

3. Base de datos y selección de variables

3.1. Fuente de información, unidad de análisis y variable objetivo

La base de datos utilizada corresponde a la Encuesta CASEN 2024, obtenida desde las fuentes oficiales del Ministerio de Desarrollo Social y Familia, junto con su respectivo libro de códigos y documentación metodológica [1, 2, 12]. Dado que el estudio se desarrolla a nivel de hogares, se filtraron las observaciones correspondientes a la jefatura del hogar mediante la variable `pco1_a`, conservando los casos donde `pco1_a` = 1. Luego del proceso de selección y limpieza, la base utilizada para el modelamiento quedó compuesta por 78.654 hogares.

La variable respuesta se construyó a partir de la variable original `pobreza`. Para formular el problema como una tarea de clasificación binaria, se definió la variable `pobreza_ingresos` de la siguiente forma:

$$\text{pobreza_ingresos} = \begin{cases} 1, & \text{si pobreza} \in \{1, 2\}, \\ 0, & \text{si pobreza} = 3. \end{cases}$$

De esta manera, el valor 1 identifica a los hogares que se encuentran en pobreza extrema o pobreza no extrema, mientras que el valor 0 identifica a los hogares fuera de pobreza, siguiendo la clasificación oficial de pobreza por ingresos utilizada en CAsEN [2]. Esta recodificación permite trabajar el problema como una clasificación supervisada binaria, ya que cada hogar queda clasificado en una de dos categorías posibles: pobreza o no pobreza [13].

A continuación, en el Cuadro 1, se presenta la distribución de la variable `pobreza_ingresos` en la base final de modelamiento, con el propósito de observar la cantidad y proporción de hogares clasificados en cada categoría.

Cuadro 1: Distribución de la variable objetivo

Categoría	Frecuencia	Porcentaje
No pobreza	63.059	80,17 %
Pobreza	15.595	19,83 %

A partir del Cuadro 1, se observa que la mayoría de los hogares de la base final se encuentra fuera de pobreza, con 63.059 casos, equivalentes al 80,17 %. En contraste, los hogares clasificados en pobreza corresponden a 15.595 casos, lo que representa el 19,83 % del total. Esta diferencia muestra que la variable objetivo presenta un desbalance entre categorías, donde la clase de interés, correspondiente a hogares en pobreza, tiene una menor representación. Por esta razón, en la etapa de modelamiento no se considerará únicamente la exactitud global del modelo, sino también métricas que permitan evaluar mejor la capacidad de identificar hogares en pobreza, como recall, F1-score y PR-AUC.

3.2. Selección de variables predictoras

La selección de variables predictoras se realizó considerando características medibles de los hogares que la literatura suele asociar con la pobreza y las condiciones socioeconómicas de los hogares. En primer lugar, se incorporaron variables laborales y de formalidad, tales como condición de actividad, contrato, cotización previsional y tasas de ocupación, desocupación e inactividad dentro del hogar. Estas variables son relevantes porque la inserción laboral, la estabilidad del empleo y la participación en sistemas formales de protección social se relacionan directamente con la capacidad de los hogares para generar ingresos y enfrentar situaciones de vulnerabilidad [5–7, 14].

En segundo lugar, se incluyeron variables educacionales y de composición del hogar. La escolaridad de la jefatura se considera relevante porque la educación se asocia con mejores oportunidades laborales, mayores retornos en el mercado del trabajo y menor probabilidad de pobreza [13, 14]. Asimismo, variables como el número de integrantes del hogar, la presencia de menores de edad, la presencia de adultos mayores y el tipo de hogar permiten aproximar la estructura familiar y las posibles cargas de dependencia, factores que pueden influir en la situación económica del hogar [5, 7, 15].

Finalmente, se incorporaron variables habitacionales y territoriales, como hacinamiento, saneamiento, materialidad, estado de la vivienda, tenencia, región y área urbana o rural. Estas variables permiten capturar condiciones materiales de vida y diferencias territoriales que pueden estar asociadas a distintos niveles de vulnerabilidad. La literatura sobre pobreza multidimensional ha destacado que las condiciones de vivienda, acceso a servicios básicos, educación y localización territorial son dimensiones relevantes para caracterizar privaciones más allá del ingreso monetario [5, 16–18].

De esta forma, el conjunto de variables predictoras busca representar distintas dimensiones observables del hogar, sin incorporar información que forme parte directa del cálculo oficial de pobreza por ingresos. Esto permite construir un modelo de clasificación que no dependa directamente de los componentes con los que se define la variable objetivo, sino de características socioeconómicas y contextuales del hogar.

3.3. Variables excluidas para evitar filtración de información

Para evitar filtración de información o *data leakage*, se excluyeron variables directamente asociadas al ingreso del hogar y al cálculo oficial de pobreza, tales como ingresos, ingreso per cápita, deciles, quintiles y líneas de pobreza. La exclusión de estas variables es necesaria porque su inclusión entregaría al modelo información demasiado cercana a la variable objetivo, generando una evaluación artificialmente optimista del desempeño predictivo [3, 4].

Por lo tanto, el modelamiento se realizó utilizando únicamente variables sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar que permiten clasificar la pobreza sin usar directamente los componentes con los que esta se calcula.

4. Preparación y limpieza de datos

Luego de definir la unidad de análisis y la variable objetivo, se realizó un proceso de preparación de datos orientado a obtener una base consistente para el análisis exploratorio y el modelamiento supervisado. En primer lugar, se conservaron únicamente las observaciones correspondientes a la jefatura del hogar mediante la variable `pco1_a`, de acuerdo con la codificación establecida en el libro de códigos de CASEN 2024 [12]. Esta decisión permitió trabajar a nivel de hogares y evitar que un mismo hogar quedara representado por múltiples integrantes, luego de esto se revisaron los valores perdidos y códigos especiales presentes en las variables seleccionadas. En encuestas sociales es común encontrar categorías asociadas a respuestas como ‘No sabe’, ‘No responde’ o ‘No aplica’, por lo que estas deben ser identificadas antes del modelamiento para evitar interpretaciones incorrectas o errores en los algoritmos [12, 19]. En este trabajo, dichos códigos fueron tratados según el significado de cada variable, y cuando correspondía se recodificaron o imputaron para mantener una base completa en las variables utilizadas.

Además, se construyeron variables derivadas relevantes para representar características del hogar. Entre ellas se encuentran la variable binaria `pobreza_ingresos` y las tasas laborales a nivel de hogar, como `tasa_ocupados_hogar`, `tasa_desocupados_hogar` y `tasa_inactivos_hogar`. El uso de tasas permite resumir la composición laboral del hogar de forma comparable entre hogares de distinto tamaño, evitando depender únicamente de conteos absolutos [5, 14].

Finalmente, se eliminaron identificadores y variables auxiliares que no aportaban información predictiva sustantiva o que podían introducir filtración de información. En particular, se excluyeron variables directamente asociadas al ingreso o derivadas del cálculo oficial de pobreza, ya que su uso podría generar *data leakage* y sobreestimar el desempeño real de los modelos [3, 4]. Tras este proceso, la base final quedó sin valores perdidos en las variables seleccionadas y preparada para las etapas posteriores de análisis exploratorio y modelamiento.

5. Análisis exploratorio de datos

El análisis exploratorio de datos se realizó con el objetivo de describir el comportamiento inicial de las variables seleccionadas y observar diferencias entre hogares en pobreza y hogares fuera de pobreza. Esta etapa permite identificar patrones relevantes antes del ajuste de los modelos supervisados, además de orientar la interpretación posterior de los resultados [13]. El análisis se centró en la distribución de

la variable respuesta y en la comparación de variables numéricas, laborales, educacionales, territoriales y habitacionales según la condición de pobreza por ingresos.

5.1. Distribución de la pobreza por ingresos

En primer lugar, se revisó la distribución de la variable `pobreza_ingresos`. Como se indicó previamente, la base final presenta un desbalance entre categorías: los hogares fuera de pobreza representan el 80,17% del total, mientras que los hogares en pobreza corresponden al 19,83 %. Esta diferencia es relevante porque, en problemas de clasificación con clases desbalanceadas, la exactitud global puede entregar una visión incompleta del desempeño del modelo, especialmente cuando la categoría de mayor interés es la menos frecuente [20].




Figura 1: Distribución de la variable `pobreza_ingresos`.

La Figura 1 permite visualizar que la mayoría de los hogares pertenece a la categoría no pobreza. Por esta razón, en la etapa de modelamiento será necesario considerar métricas complementarias a la exactitud, tales como recall, F1-score y PR-AUC, las cuales permiten evaluar de mejor manera la capacidad de los modelos para identificar hogares en pobreza.

5.2. Variables numéricas según pobreza

A continuación, se compararon algunas variables numéricas entre hogares fuera de pobreza y hogares en pobreza. El Cuadro 2 presenta los promedios por grupo y la diferencia observada entre ambas categorías.

Cuadro 2: Promedios de variables numéricas según condición de pobreza

Variable	No pobreza	Pobreza	Diferencia
Edad de la jefatura	55,02	53,38	-1,64
Escolaridad	11,65	9,77	-1,87
Número de personas	2,78	2,75	-0,04
Tasa de ocupados	0,52	0,23	-0,28
Tasa de desocupados	0,03	0,08	0,05
Tasa de inactivos	0,35	0,52	0,17

Los resultados del Cuadro 2 muestran diferencias en la escolaridad promedio de la jefatura del hogar. En los hogares fuera de pobreza, la escolaridad promedio alcanza 11,65 años, mientras que en los hogares en pobreza disminuye a 9,77 años. Esta diferencia sugiere que los hogares en pobreza tienden a presentar menores niveles educativos en su jefatura, lo cual es consistente con la literatura que vincula la educación con mejores oportunidades laborales, mayores ingresos potenciales y menor vulnerabilidad socioeconómica [5, 14].

También se observan diferencias importantes en las variables laborales construidas a nivel de hogar. La tasa promedio de ocupados es considerablemente menor en los hogares en pobreza, mientras que las tasas de desocupación e inactividad son mayores. Esto sugiere que la inserción laboral del hogar es una dimensión relevante para distinguir entre hogares en pobreza y hogares fuera de pobreza. En cambio, la diferencia en el número promedio de personas del hogar es pequeña, por lo que esta variable, de manera descriptiva, no muestra una separación tan marcada entre ambos grupos.

Los gráficos complementan la comparación anterior, mostrando visualmente las diferencias en escolaridad y tasas laborales entre ambos grupos.




Figura 2: Comparación de variables numéricas relevantes según condición de pobreza.

La Figura 2 permite observar gráficamente que la escolaridad tiende a ser menor en hogares en pobreza y que las diferencias laborales son más marcadas en la tasa de ocupados y en la tasa de inactivos. Estas diferencias refuerzan la importancia de incluir variables laborales y educativas en el proceso de clasificación.

5.3. Variables laborales y de formalidad

Dado que las variables laborales presentaron diferencias relevantes en el análisis numérico, se revisó también el comportamiento de variables categóricas asociadas a inserción y formalidad laboral, tales como condición de actividad, contrato y cotización previsional. Estas variables permiten aproximar el vínculo de la jefatura del hogar con el mercado laboral y con mecanismos de protección social.




Figura 3: Proporción de pobreza según variables laborales y de formalidad.

En la Figura 3 se observa que la proporción de pobreza varía según la situación laboral y el grado de formalidad. En particular, los hogares con jefaturas desocupadas o inactivas tienden a presentar mayores niveles de pobreza que aquellos con jefaturas ocupadas. Asimismo, la ausencia de contrato o cotización previsional se asocia descriptivamente con una mayor proporción de pobreza. Estos resultados son coherentes con la importancia de la inserción laboral y la formalidad como dimensiones vinculadas a la estabilidad económica del hogar [5–7].

5.4. Variables educacionales y composición del hogar

Además de las variables laborales, se analizaron variables asociadas a escolaridad y composición del hogar. La composición familiar puede incidir en la situación económica del hogar, debido a diferencias en cargas de dependencia, número de integrantes y presencia de menores o adultos mayores [5, 15].




Figura 4: Proporción de pobreza según composición del hogar.

La Figura 4 permite comparar la proporción de pobreza según la presencia de menores de 18 años y adultos mayores en el hogar. En términos generales, la presencia de menores puede asociarse con mayores cargas económicas, mientras que la presencia de adultos mayores puede tener efectos distintos dependiendo de la composición y fuentes de ingreso del hogar. Estos resultados se interpretan de forma descriptiva, ya que el objetivo del análisis exploratorio no es establecer causalidad, sino identificar patrones relevantes para el modelamiento.

Adicionalmente, se revisó la proporción de pobreza según tipo de hogar:




Figura 5: Proporción de pobreza según tipo de hogar.

El tipo de hogar permite observar diferencias entre hogares unipersonales, nucleares, extensos u otros arreglos familiares. Esta variable puede aportar información relevante al modelo, ya que resume parte de la estructura familiar y de las posibles dependencias internas del hogar.

5.5. Variables territoriales y habitacionales

También se exploraron variables territoriales y habitacionales, ya que las condiciones materiales de vida y el lugar de residencia pueden estar asociadas a distintos niveles de vulnerabilidad. La literatura sobre pobreza multidimensional reconoce que aspectos como vivienda, servicios básicos, hacinamiento y territorio permiten caracterizar privaciones que no siempre quedan completamente reflejadas en el ingreso monetario [16–18].




Figura 6: Proporción de pobreza según variables territoriales.

La Figura 6 permite observar diferencias territoriales en la proporción de hogares en pobreza. En particular, se espera que la pobreza presente variaciones entre zonas urbanas y rurales, así como entre regiones. Estas diferencias justifican la inclusión de variables territoriales en el modelamiento, ya que el contexto geográfico puede aportar información relevante para clasificar la condición de pobreza.




Figura 7: Proporción de pobreza según condiciones habitacionales seleccionadas.

La Figura 7 permite revisar si la pobreza se concentra en hogares con peores condiciones habitacionales. En general, se espera que situaciones como hacinaamiento o saneamiento deficitario se asocien con una mayor proporción de pobreza, lo cual refuerza la utilidad de incluir variables de vivienda como predictores en los modelos.

5.6. Asociaciones bivariadas

Con el objetivo de complementar el análisis exploratorio, se revisaron asociaciones bivariadas entre las variables predictoras y la variable objetivo. Para las variables categóricas se utilizó la V de Cramer, medida que permite resumir el grado de asociación entre dos variables categóricas. En el caso de las variables numéricas, se revisaron asociaciones descriptivas mediante correlaciones y comparaciones entre hogares en pobreza y hogares fuera de pobreza.




Figura 8: Asociaciones bivariadas entre variables predictoras y pobreza por ingresos.

La Figura 8 permite identificar qué variables presentan mayor relación descriptiva con la condición de pobreza por ingresos. En el caso de las variables categóricas, se observa que las asociaciones más relevantes se concentran en variables laborales, de formalidad y habitacionales, tales como cotización previsional, contrato, condición de actividad y condiciones de vivienda. Esto coincide con el análisis previo, donde estas dimensiones mostraron diferencias importantes entre hogares en pobreza y hogares fuera de pobreza.

En cuanto a las variables numéricas, las asociaciones descriptivas refuerzan la importancia de la esco-

laridad y de las tasas laborales del hogar. En particular, una menor tasa de ocupados y una mayor tasa de inactivos aparecen relacionadas con la condición de pobreza, lo que sugiere que la composición laboral del hogar aporta información relevante para el modelamiento.




Figura 9: Matriz de correlaciones de variables numéricas seleccionadas.

La Figura 9 muestra las correlaciones entre la variable objetivo y las principales variables numéricas seleccionadas. En relación con la pobreza por ingresos, se observa una correlación negativa con la tasa de ocupados del hogar (-0,33) y con la escolaridad de la jefatura (-0,17). Esto indica que, descriptivamente, los hogares con mayor proporción de personas ocupadas y mayor escolaridad tienden a presentar menor presencia de pobreza. Por el contrario, la pobreza se relaciona positivamente con la tasa de inactivos (0,19) y con la tasa de desocupados (0,14), lo que es coherente con la importancia de la inserción laboral del hogar en la clasificación de pobreza.

También se observan correlaciones relevantes entre algunas variables predictoras. La relación más fuerte aparece entre la tasa de ocupados y la tasa de inactivos (-0,79), lo cual es esperable, ya que ambas variables describen componentes opuestos de la situación laboral del hogar. Además, la edad de la jefatura presenta una correlación positiva con la presencia de adultos mayores (0,76) y con la tasa de inactivos (0,56), mientras que el número de personas del hogar se relaciona positivamente con la presencia de menores (0,64). Estas asociaciones muestran que algunas variables capturan dimensiones similares de composición y estructura del hogar.

En general, la matriz de correlaciones permite confirmar que las variables laborales y educacionales presentan una relación descriptiva relevante con la pobreza por ingresos. No obstante, estas correlaciones deben interpretarse con cautela, ya que corresponden a relaciones bivariadas y no permiten establecer causalidad ni considerar simultáneamente el efecto del resto de las variables. Por esta razón, el análisis posterior mediante modelos supervisados permite evaluar estas relaciones de manera conjunta.

5.7. Síntesis del análisis exploratorio

En síntesis, el análisis exploratorio muestra que la pobreza por ingresos se diferencia principalmente en variables laborales, educacionales, de formalidad y condiciones del hogar. Los hogares en pobreza presentan menor escolaridad promedio, menor tasa de ocupados y mayores niveles de desocupación e inactividad.

Además, las variables de contrato, cotización y condición de actividad muestran diferencias relevantes entre grupos, lo que refuerza la importancia de la inserción laboral y la formalidad.

También se observaron diferencias en variables de composición familiar, vivienda y territorio. Estas dimensiones no deben interpretarse como causas directas de pobreza, sino como características asociadas descriptivamente a la condición socioeconómica de los hogares. En conjunto, los resultados del EDA respaldan la selección de variables predictoras y justifican avanzar hacia modelos supervisados capaces de evaluar simultáneamente la contribución de estas características en la clasificación de hogares en pobreza y no pobreza.

6. Metodología de modelamiento

En esta sección se describe la estrategia utilizada para ajustar y evaluar los modelos supervisados de clasificación. La metodología considera la definición del tipo de problema, la partición de los datos, el preprocesamiento aplicado a las variables, las métricas de evaluación y los procedimientos utilizados para la validación y ajuste de modelos.

6.1. Tipo de problema

El problema abordado corresponde a una tarea de clasificación supervisada binaria, ya que se dispone de una variable respuesta conocida para cada hogar y el objetivo es predecir una de dos categorías posibles. En este caso, la variable objetivo es **pobreza_ingresos**, construida a partir de la clasificación oficial de pobreza por ingresos de CASEN 2024.

La variable toma el valor 1 cuando el hogar se encuentra en pobreza extrema o pobreza no extrema, y el valor 0 cuando el hogar se encuentra fuera de pobreza. Por lo tanto, el valor 1 representa la categoría de mayor interés para el estudio, correspondiente a hogares en pobreza, mientras que el valor 0 representa a los hogares fuera de pobreza.

Desde el punto de vista del aprendizaje supervisado, el modelo busca aprender patrones presentes en las variables predictoras para clasificar correctamente a los hogares según su condición de pobreza. Esta formulación permite comparar distintos algoritmos de clasificación, evaluando tanto su capacidad predictiva como la interpretación de las variables asociadas al resultado [13].

6.2. Partición de datos

Para evaluar el desempeño de los modelos, la base de datos fue dividida en dos subconjuntos: un conjunto de entrenamiento y un conjunto de prueba. El 70 % de las observaciones fue utilizado para entrenar los modelos, mientras que el 30 % restante se reservó para evaluar su desempeño predictivo sobre datos no utilizados durante el entrenamiento.

La partición se realizó de manera estratificada según la variable **pobreza_ingresos**. Esta decisión es importante debido al desbalance observado en la variable objetivo, donde los hogares en pobreza representan una proporción menor del total. La estratificación permite mantener una distribución similar de hogares en pobreza y fuera de pobreza tanto en el conjunto de entrenamiento como en el conjunto de prueba, evitando que alguno de los subconjuntos quede con una representación inadecuada de la categoría menos frecuente [20].

De esta forma, la evaluación en el conjunto de prueba entrega una aproximación más confiable del desempeño esperado del modelo en datos nuevos, manteniendo la estructura original de la variable objetivo.

6.3. Preprocesamiento

El preprocesamiento de los datos se realizó considerando el tipo de variable y las características de cada algoritmo. En primer lugar, las variables categóricas fueron transformadas mediante codificación *One-Hot Encoding*. Esta técnica permite representar cada categoría como una variable binaria, evitando asignar un orden numérico artificial a categorías que no necesariamente tienen una relación ordinal.

Para la regresión logística se aplicó además estandarización de las variables numéricas mediante *StandardScaler*. Este procedimiento transforma las variables para que tengan media cero y desviación estándar uno, lo cual es recomendable en modelos lineales cuando las variables se encuentran en escalas distintas. En este caso, la estandarización permite comparar de manera más estable variables como edad, escolaridad, número de personas y tasas laborales.

En cambio, los modelos basados en árboles de decisión y Random Forest no requieren estandarización de las variables numéricas, ya que realizan particiones sucesivas del espacio de predictores y no dependen directamente de la escala de medición de las variables. Por esta razón, para estos modelos se mantuvieron las variables numéricas en su escala original, aplicando únicamente la codificación necesaria para las variables categóricas [9, 10].

6.4. Métricas de evaluación

Dado que la variable objetivo presenta desbalance entre hogares en pobreza y hogares fuera de pobreza, la evaluación de los modelos no se basó únicamente en la exactitud global. En problemas de clasificación desbalanceada, un modelo puede obtener una alta exactitud si predice correctamente la categoría mayoritaria, pero aun así presentar bajo desempeño para identificar la categoría de mayor interés [20].

Para definir las métricas se consideraron los siguientes elementos de la matriz de confusión: verdaderos positivos (TP), hogares en pobreza correctamente clasificados como pobreza; verdaderos negativos (TN), hogares fuera de pobreza correctamente clasificados como no pobreza; falsos positivos (FP), hogares fuera de pobreza clasificados incorrectamente como pobreza; y falsos negativos (FN), hogares en pobreza clasificados incorrectamente como no pobreza.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

La exactitud o *accuracy* mide la proporción total de clasificaciones correctas. La precisión indica, entre los hogares clasificados como pobreza, qué proporción efectivamente corresponde a hogares en pobreza. El *recall* mide la capacidad del modelo para identificar correctamente a los hogares que realmente se encuentran en pobreza. Por su parte, el F1-score resume el equilibrio entre precisión y recall, siendo útil cuando se busca balancear ambos aspectos.

Además, se consideraron las métricas ROC-AUC y PR-AUC. La ROC-AUC evalúa la capacidad general del modelo para distinguir entre ambas categorías a distintos umbrales de clasificación. Sin embargo, en contextos con clases desbalanceadas, la PR-AUC resulta especialmente relevante, ya que se enfoca en la relación entre precisión y recall para la categoría de interés.

En este trabajo, el F1-score fue considerado como criterio principal de comparación, debido a que permite equilibrar la identificación de hogares en pobreza con la calidad de las predicciones positivas. Esto es especialmente importante porque el objetivo no es solo clasificar correctamente a la mayoría de los hogares, sino también reconocer de forma adecuada a aquellos que se encuentran en situación de pobreza.

6.5. Validación cruzada y ajuste de hiperparámetros

Para mejorar la evaluación de los modelos y reducir la dependencia de una única partición de los datos, se utilizó validación cruzada estratificada durante el proceso de ajuste. Este procedimiento divide el conjunto de entrenamiento en varios subconjuntos, manteniendo la proporción de hogares en pobreza y fuera de pobreza en cada división. De esta forma, el desempeño promedio del modelo se estima a partir de distintas particiones internas del conjunto de entrenamiento.

En el caso de la regresión logística, además del modelo completo, se ajustó una versión parsimoniosa mediante selección *forward*. Este procedimiento permite construir un modelo más simple incorporando progresivamente variables predictoras según su aporte al desempeño del modelo. La finalidad de este enfoque fue comparar un modelo más interpretable con modelos de mayor complejidad.

Para Random Forest se realizó un ajuste de hiperparámetros mediante `GridSearchCV`. Este procedimiento evalúa distintas combinaciones de parámetros, tales como número de árboles, profundidad máxima, número mínimo de observaciones por hoja y número de variables consideradas en cada partición. La búsqueda se realizó utilizando validación cruzada estratificada y considerando el F1-score como criterio principal de selección.

En conjunto, estos procedimientos permiten comparar modelos de manera más robusta, evitando basar la elección únicamente en el desempeño observado en una sola partición de entrenamiento y prueba. Así, la metodología busca equilibrar capacidad predictiva, control del sobreajuste e interpretación de los resultados.

7. Modelos utilizados

7.1. Regresión logística completa

La regresión logística completa se utilizó como modelo interpretable para clasificar la condición de pobreza por ingresos. Este modelo permite estimar la probabilidad de que un hogar pertenezca a la clase pobreza y, al mismo tiempo analizar la dirección de la asociación entre las variables predictoras y la respuesta.

En este caso, se ajustó una versión balanceada mediante `class_weight = "balanced"`, con el objetivo de mejorar la identificación de la clase minoritaria, correspondiente a los hogares en pobreza. Esto resulta relevante debido al desbalance observado previamente en la variable objetivo.

Además, la regresión logística permite transformar sus coeficientes en *odds ratios*, facilitando la interpretación de los resultados. Un *odds ratio* mayor que 1 se asocia con mayores chances estimadas de pobreza, mientras que un valor menor que 1 se asocia con menores chances estimadas, manteniendo constantes las demás variables del modelo.

Finalmente, dado que las variables numéricas fueron estandarizadas, sus coeficientes se interpretan en función de aumentos de una desviación estándar y no en unidades originales de medición.

7.2. Regresión logística parsimoniosa

Además de la regresión logística completa, se ajustó una versión parsimoniosa con el objetivo de obtener un modelo más simple e interpretable. Para ello, se utilizó un procedimiento de selección *forward*

con validación cruzada estratificada, empleando el F1-score como criterio de selección.

En cada paso se evaluó la incorporación de una nueva variable candidata y se agregó aquella que generaba el mayor aumento en el F1-score promedio. La selección se detuvo cuando la mejora obtenida fue menor al criterio mínimo definido. Como resultado, el modelo parsimonioso *forward* seleccionó cuatro variables: `tasa_ocupados_hogar`, `may60c`, `cotiza` y `ten_viv_f`.

También se evaluó una versión parsimoniosa extendida, incorporando la variable `esc`. Esta decisión se tomó porque la escolaridad quedó cercana al criterio de entrada y, además, posee una justificación teórica relevante en el estudio de la pobreza. De esta forma, el modelo extendido quedó compuesto por cinco variables: `tasa_ocupados_hogar`, `may60c`, `cotiza`, `ten_viv_f` y `esc`.

Este modelo se utilizó como comparación de parsimonia frente a la regresión logística completa, ya que permite evaluar cuánto desempeño predictivo se pierde al trabajar con una cantidad menor de variables. Por lo tanto, su utilidad principal es entregar una alternativa más simple, manteniendo variables sustantivamente relevantes para la clasificación de pobreza por ingresos.

7.3. Árbol de decisión

El árbol de decisión se incorporó como un modelo no lineal simple, capaz de clasificar la pobreza por ingresos a partir de reglas de partición sucesivas sobre las variables predictoras. A diferencia de la regresión logística, este modelo puede captar relaciones no lineales e interacciones entre variables sin necesidad de especificarlas previamente.

Para su ajuste se utilizaron las mismas 25 variables predictoras consideradas en los otros modelos. En particular, se definieron los parámetros `max_depth = 6`, `min_samples_leaf = 100` y `class_weight = "balanced"`. La profundidad máxima se acotó para evitar un crecimiento excesivo del árbol, mientras que el número mínimo de observaciones por hoja permitió reducir particiones demasiado pequeñas y mejorar la estabilidad del modelo.

Este modelo se utilizó principalmente como referencia intermedia entre la interpretabilidad de la regresión logística y la mayor capacidad predictiva de Random Forest. Además, su representación gráfica permite visualizar de forma clara algunas de las reglas de decisión más relevantes en la clasificación de hogares en pobreza y no pobreza.

7.4. Random Forest ajustado

El Random Forest ajustado se utilizó como modelo de ensamble basado en múltiples árboles de decisión. A diferencia de un árbol individual, este método combina varios árboles entrenados sobre distintas muestras de los datos, lo que permite mejorar la estabilidad del modelo y reducir el riesgo de sobreajuste.

Este modelo fue considerado como la alternativa con mayor capacidad predictiva dentro del análisis, ya que puede capturar relaciones no lineales e interacciones entre variables sin requerir una especificación previa. Además, permite trabajar con un conjunto amplio de predictores y entregar medidas de importancia de variables.

Para seleccionar la configuración final del modelo se aplicó una búsqueda de hiperparámetros mediante `GridSearchCV` con validación cruzada estratificada. El criterio utilizado para elegir la mejor combinación fue el F1-score, debido a que permite equilibrar precisión y recall en un contexto de clases desbalanceadas.

Los hiperparámetros finales seleccionados para el Random Forest ajustado se presentan en el Cuadro 3. Esta configuración corresponde al modelo utilizado posteriormente para la comparación final de desempeño y para el análisis de importancia de variables.

Cuadro 3: Hiperparámetros seleccionados para el Random Forest ajustado

Hiperparámetro	Valor seleccionado
<code>n_estimators</code>	300
<code>max_depth</code>	14
<code>min_samples_leaf</code>	30
<code>max_features</code>	sqrt
<code>class_weight</code>	balanced_subsample

8. Resultados

8.1. Comparación final de modelos

El Cuadro 4 presenta la comparación final entre los modelos evaluados. En términos generales, el Random Forest ajustado obtuvo el mejor desempeño global, alcanzando un accuracy de 0,769, una precision de 0,454, un recall de 0,813, un F1-score de 0,582, un ROC-AUC de 0,863 y un PR-AUC de 0,617. Este modelo fue el mejor según F1-score, ROC-AUC y PR-AUC, por lo que se seleccionó como modelo predictivo final.

La regresión logística balanceada completa también presentó un desempeño competitivo, con un F1-score de 0,562, ROC-AUC de 0,849 y PR-AUC de 0,583. Aunque fue superada por el Random Forest ajustado, sigue siendo relevante dentro del análisis debido a su mayor interpretabilidad, ya que permite analizar coeficientes y *odds ratios*.

El árbol de decisión obtuvo el mayor recall entre todos los modelos, con un valor de 0,830. Esto indica que fue el modelo que logró identificar una mayor proporción de hogares en pobreza. Sin embargo, su precision fue menor, alcanzando 0,407, lo que muestra que también clasificó como pobres a una mayor cantidad de hogares que realmente no pertenecían a dicha categoría.

Por último, la regresión logística parsimoniosa extendida presentó el menor desempeño relativo, con un F1-score de 0,512, ROC-AUC de 0,807 y PR-AUC de 0,527. A pesar de esto, su utilidad radica en que permite comparar cuánto desempeño se pierde al utilizar un modelo más simple y con menos variables. En conjunto, los resultados muestran que el Random Forest ajustado logra el mejor equilibrio entre capacidad predictiva y detección de hogares en pobreza.

Cuadro 4: Comparación final de modelos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
Logística balanceada completa	0,759	0,440	0,779	0,562	0,849	0,583
Logística parsimoniosa extendida	0,714	0,387	0,759	0,512	0,807	0,527
Árbol de decisión	0,726	0,407	0,830	0,546	0,843	0,555
Random Forest ajustado	0,769	0,454	0,813	0,582	0,863	0,617

8.2. Matriz de confusión del modelo final

El Cuadro 5 presenta la matriz de confusión del Random Forest ajustado, seleccionado como modelo final. En el conjunto de prueba, el modelo clasificó correctamente a 14.337 hogares fuera de pobreza, correspondientes a los verdaderos negativos, y a 3.803 hogares en pobreza, correspondientes a los verdaderos positivos.

También se observaron 876 falsos negativos, es decir, hogares que realmente se encontraban en pobreza, pero fueron clasificados como no pobreza. Este tipo de error es relevante en el contexto del estudio, ya que implica no detectar hogares pertenecientes a la clase de mayor interés. Sin embargo, el número de falsos negativos es relativamente bajo en comparación con el total de hogares en pobreza del conjunto de prueba, lo que se refleja en un recall de 0,813.

Por otra parte, el modelo presentó 4.581 falsos positivos, correspondientes a hogares fuera de pobreza que fueron clasificados como pobreza. Esto explica que la precisión del modelo sea de 0,454. En otras palabras, el modelo prioriza la detección de hogares en pobreza, aunque a costa de clasificar erróneamente a algunos hogares fuera de pobreza.

En este trabajo, dicho comportamiento resulta aceptable, ya que el objetivo principal es reconocer adecuadamente a los hogares en situación de pobreza. No obstante, estos resultados deben interpretarse como una herramienta de apoyo al análisis predictivo y no como reemplazo de la medición oficial de pobreza por ingresos.

Cuadro 5: Matriz de confusión del Random Forest ajustado

	Predicho: No pobreza	Predicho: Pobreza
Real: No pobreza	14.337	4.581
Real: Pobreza	876	3.803

8.3. Curvas ROC y Precision-Recall

Las Figuras 10 y 11 presentan las curvas ROC y Precision-Recall comparativas de los modelos evaluados. La curva ROC permite analizar la capacidad de discriminación de cada modelo entre hogares en pobreza y hogares fuera de pobreza a distintos umbrales de clasificación. En este caso, el Random Forest ajustado presentó el mayor ROC-AUC, con un valor de 0,863, seguido por la regresión logística completa con 0,849 y el árbol de decisión con 0,843.

Estos resultados indican que el Random Forest ajustado es el modelo con mejor capacidad general para separar ambas clases. La regresión logística completa también muestra un desempeño cercano, lo que confirma que es un modelo competitivo, aunque levemente inferior en términos predictivos.

La curva Precision-Recall resulta especialmente importante debido al desbalance de la variable objetivo. En esta curva, el Random Forest ajustado obtuvo el mayor PR-AUC, con un valor de 0,617. Este resultado indica que el modelo mantiene el mejor equilibrio entre precisión y recall para la clase positiva, correspondiente a los hogares en pobreza.

Además, la curva Precision-Recall muestra que todos los modelos superan la línea base asociada a la prevalencia de pobreza en el conjunto de prueba, cercana a 0,198. Esto significa que los modelos logran entregar información predictiva útil más allá de la proporción inicial de hogares en pobreza. En conjunto, las curvas respaldan la selección del Random Forest ajustado como modelo final.




Figura 10: Curva ROC comparativa de los modelos evaluados




Figura 11: Curva Precision-Recall comparativa de los modelos evaluados

9. Importancia de variables del modelo final

El Cuadro 6 presenta las variables más importantes según el Random Forest ajustado. La variable con mayor importancia relativa fue `tasa_ocupados_hogar`, con un 24,58 %. Esto indica que la composición laboral del hogar fue el principal elemento utilizado por el modelo para clasificar la condición de pobreza por

ingresos. Este resultado es coherente con el análisis exploratorio, donde los hogares en pobreza presentaban una menor tasa promedio de ocupados.

En segundo y tercer lugar aparecen las variables `cotiza` y `contrato`, con importancias relativas de 11,06 % y 10,19 %, respectivamente. Ambas variables están asociadas a la formalidad laboral, lo que sugiere que no solo importa la presencia de ocupación en el hogar, sino también las condiciones formales del vínculo laboral. Esto refuerza la importancia de la inserción laboral y la protección social en la clasificación de pobreza por ingresos.

También destacan variables como `edad` y `esc`, con importancias de 6,63 % y 5,79 %, respectivamente. La escolaridad de la jefatura del hogar aparece como un predictor relevante, lo que coincide con los resultados descriptivos observados previamente, donde los hogares en pobreza presentaban menores años promedio de escolaridad.

Además, variables como `activ`, `tipohogar`, `may60c`, `tasa_inactivos_hogar` y `men18c` muestran que la composición laboral y familiar del hogar también aporta información al proceso de clasificación. En conjunto, estos resultados indican que el modelo utiliza principalmente dimensiones laborales, de formalidad, educación y composición del hogar para distinguir entre hogares en pobreza y hogares fuera de pobreza.

Es importante señalar que la importancia de variables en Random Forest no indica la dirección del efecto ni debe interpretarse como una relación causal. Una mayor importancia relativa solo significa que la variable aportó más al proceso predictivo del modelo. Por lo tanto, estos resultados deben entenderse como asociaciones predictivas útiles para la clasificación, no como evidencia de causalidad.

Cuadro 6: Variables más importantes según Random Forest ajustado

Variable	Importancia relativa
<code>tasa_ocupados_hogar</code>	24,58 %
<code>cotiza</code>	11,06 %
<code>contrato</code>	10,19 %
<code>edad</code>	6,63 %
<code>esc</code>	5,79 %
<code>activ</code>	4,93 %
<code>tipohogar</code>	4,60 %
<code>may60c</code>	4,53 %
<code>tasa_inactivos_hogar</code>	4,31 %
<code>men18c</code>	3,70 %

10. Conclusiones

A partir del objetivo planteado, se concluye que fue posible clasificar la condición de pobreza por ingresos de los hogares chilenos utilizando variables sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar provenientes de la Encuesta CASEN 2024. Para ello, se construyó una base final a nivel de hogares, considerando como unidad de análisis a la jefatura del hogar y definiendo una variable objetivo binaria que distingue entre hogares en pobreza y hogares fuera de pobreza.

Un aspecto central del trabajo fue evitar la filtración de información o *data leakage*. Por esta razón, no se utilizaron como predictoras variables directamente relacionadas con ingresos, deciles, quintiles o líneas de pobreza, ya que estas forman parte del cálculo oficial de la pobreza por ingresos. De esta manera, los modelos fueron evaluados a partir de características observables del hogar y no desde información directamente derivada de la variable objetivo.

En la etapa de modelamiento se compararon distintos modelos supervisados de clasificación: regresión logística balanceada completa, regresión logística parsimoniosa extendida, árbol de decisión y Random Forest ajustado. La comparación mostró que el Random Forest ajustado fue el mejor modelo predictivo, alcanzando el mayor F1-score, ROC-AUC y PR-AUC. Esto indica que presentó el mejor equilibrio entre capacidad de clasificación general y detección de hogares en pobreza.

Por otro lado, la regresión logística balanceada completa fue útil como modelo interpretable, ya que permitió analizar la dirección de las asociaciones mediante coeficientes y *odds ratios*. Aunque su desempeño fue levemente inferior al del Random Forest ajustado, entregó una lectura más clara sobre cómo ciertas variables se relacionan con la probabilidad estimada de pobreza.

En cuanto a las variables más relevantes, los resultados del Random Forest ajustado mostraron que las dimensiones laborales y de formalidad fueron las que tuvieron mayor peso predictivo. En particular, destacaron la tasa de ocupados del hogar, la cotización previsional y el contrato laboral. También fueron importantes variables como escolaridad, edad, condición de actividad y composición del hogar, lo que confirma que la pobreza por ingresos se relaciona con múltiples características del hogar.

Finalmente, es importante señalar que los resultados obtenidos deben interpretarse como asociaciones predictivas y no como relaciones causales. Es decir, los modelos permiten identificar variables que ayudan a clasificar hogares en pobreza, pero no permiten afirmar que dichas variables causen directamente la pobreza por ingresos. Por lo tanto, el análisis desarrollado constituye una herramienta complementaria para estudiar patrones asociados a la vulnerabilidad socioeconómica, sin reemplazar la medición oficial de pobreza.

Referencias

- [1] Ministerio de Desarrollo Social y Familia. Base de datos casen 2024, 2024. URL <https://bidat.gob.cl/details/ficha/dataset/base-de-datos-casen-2024>. Banco Integrado de Datos, base de datos y documentación oficial de CASEN 2024. Consultado en 2026.
- [2] Ministerio de Desarrollo Social y Familia. Metodología de medición de la pobreza por ingresos 2024, 2024. URL https://observatorio.ministeriodesarrollosocial.gob.cl/storage/docs/casen/2024/Metodologia_de_Medicion_de_la_Pobreza_por_Ingresos_2024.pdf. Documento metodológico oficial de CASEN 2024. Consultado en 2026.
- [3] Scikit-learn developers. Common pitfalls and recommended practices: Data leakage, 2026. URL https://scikit-learn.org/stable/common_pitfalls.html. Consultado en 2026.
- [4] Sayash Kapoor and Arvind Narayanan. Leakage and the reproducibility crisis in ml-based science. *arXiv preprint arXiv:2207.07048*, 2022.
- [5] Comisión Económica para América Latina y el Caribe. Panorama social de américa latina y el caribe 2024, 2024. URL <https://www.cepal.org/es/publicaciones/80858-panorama-social-america-latina-caribe-2024>. Consultado en 2026.
- [6] Berta Teitelboim. Factores determinantes de la pobreza en chile: un análisis mediante modelos de elección discreta, 2006. Documento de trabajo.
- [7] Christopher Neilson, Dante Contreras, Ryan Cooper, and Jorge Hermann. The dynamics of poverty in chile. *Journal of Latin American Studies*, 2008.
- [8] David W. Hosmer, Stanley Lemeshow, and Rodney X. Sturdivant. *Applied Logistic Regression*. Wiley, 3 edition, 2013.
- [9] Leo Breiman, Jerome H. Friedman, Richard A. Olshen, and Charles J. Stone. *Classification and Regression Trees*. Wadsworth, 1984.
- [10] Leo Breiman. Random forests. *Machine Learning*, 45:5–32, 2001.
- [11] Scikit-learn developers. Randomforestclassifier, 2026. URL <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>. Consultado en 2026.
- [12] Ministerio de Desarrollo Social y Familia. Libro de códigos base de datos casen 2024, 2024. URL <https://observatorio.ministeriodesarrollosocial.gob.cl/encuesta-casen-2024>. Documento disponible en la sección Bases de datos de la Encuesta CASEN 2024. Consultado en 2026.
- [13] Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: With Applications in R*. Springer, 2 edition, 2021. URL <https://www.statlearning.com/>.
- [14] World Bank. Introduction to poverty analysis. Technical report, World Bank, 2005. URL <https://documents1.worldbank.org/curated/en/775871468331250546/pdf/902880WP0Box380okPovertyAnalysisEng.pdf>. Consultado en 2026.
- [15] Organisation for Economic Co-operation and Development. How’s life in latin america? measuring well-being for policy making. Technical report, OECD Publishing, 2021. URL https://www.oecd.org/content/dam/oecd/en/publications/reports/2021/10/how-s-life-in-latin-america_e373e4e2/2965f4fe-en.pdf. Consultado en 2026.

- [16] Maria Emma Santos and Pablo Villatoro. A multidimensional poverty index for latin america. Technical report, OPHI, 2015. URL https://ophi.org.uk/sites/default/files/2024-01/OPHIWP079_0.pdf. Consultado en 2026.
- [17] United Nations Development Programme. Global multidimensional poverty index 2025, 2025. URL <https://hdr.undp.org/content/2025-global-multidimensional-poverty-index-mpi>. Consultado en 2026.
- [18] World Bank. Multidimensional poverty measure, 2026. URL <https://www.worldbank.org/en/topic/poverty/brief/multidimensional-poverty-measure>. Consultado en 2026.
- [19] Roderick J. A. Little and Donald B. Rubin. *Statistical Analysis with Missing Data*. Wiley, 3 edition, 2019.
- [20] Haibo He and Edwardo A. Garcia. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9):1263–1284, 2009. doi: 10.1109/TKDE.2008.239.

A. Variables utilizadas

En este anexo se presenta el conjunto de variables utilizadas en el modelamiento supervisado. Las variables fueron seleccionadas considerando dimensiones sociodemográficas, laborales, educacionales, habitacionales, territoriales y de composición del hogar. No se incorporaron variables directamente asociadas a ingresos, deciles, quintiles o líneas de pobreza, con el fin de evitar filtración de información.

Cuadro 7: Variables predictoras utilizadas en el modelamiento

Variable	Tipo	Dimensión
edad	Numérica	Sociodemográfica
esc	Numérica	Educacional
numper	Numérica	Composición del hogar
tasa_ocupados_hogar	Numérica	Laboral
tasa_desocupados_hogar	Numérica	Laboral
tasa_inactivos_hogar	Numérica	Laboral
jefatura_mujer	Categórica	Sociodemográfica
ecivil	Categórica	Sociodemográfica
activ	Categórica	Laboral
contrato	Categórica	Formalidad laboral
cotiza	Categórica	Formalidad laboral
disc_wg	Categórica	Sociodemográfica
pueblos_indigenas	Categórica	Sociodemográfica
nacido_fuera_chile	Categórica	Sociodemográfica
tipohogar	Categórica	Composición del hogar
men18c	Categórica	Composición del hogar
may60c	Categórica	Composición del hogar
region	Categórica	Territorial
area	Categórica	Territorial
ind_hacina	Categórica	Habitacional
ind_san	Categórica	Habitacional
ind_mat	Categórica	Habitacional
ind_estado	Categórica	Habitacional
ind_cal_glob	Categórica	Habitacional
ten_viv_f	Categórica	Habitacional

B. Árbol de decisión

En este anexo se presenta una visualización simplificada de los primeros niveles del árbol de decisión. Esta representación permite observar algunas reglas iniciales utilizadas por el modelo para separar hogares en pobreza y hogares fuera de pobreza. La visualización se incluye como apoyo interpretativo, ya que el árbol completo puede ser demasiado extenso para incorporarlo en el cuerpo principal del informe.

Árbol de decisión simplificado: primeros niveles




Figura 12: Visualización simplificada de los primeros niveles del árbol de decisión

C. Tabla completa de importancia de variables

En este anexo se presenta la importancia relativa completa de las variables utilizadas por el Random Forest ajustado. La tabla corresponde a la importancia agrupada por variable original, luego del preprocesamiento aplicado a las variables categóricas. Estos valores indican el aporte predictivo de cada variable al modelo, pero no deben interpretarse como dirección del efecto ni como evidencia causal.

Cuadro 8: Importancia completa de variables según Random Forest ajustado

Variable	Importancia relativa
tasa_ocupados_hogar	24,58 %
cotiza	11,06 %
contrato	10,19 %
edad	6,63 %
esc	5,79 %
activ	4,93 %
tipohogar	4,60 %
may60c	4,53 %
tasa_inactivos_hogar	4,31 %
men18c	3,70 %
ecivil	3,27 %
ten_viv_f	2,89 %
ind_estado	2,75 %
numper	2,61 %
tasa_desocupados_hogar	1,74 %
jefatura_mujer	1,54 %
region	1,07 %
ind_cal_glob	0,76 %
nacido_fuera_chile	0,74 %
ind_hacina	0,55 %
area	0,53 %
ind_san	0,34 %
disc_wg	0,33 %
ind_mat	0,29 %
pueblos_indigenas	0,27 %

D. Notebook y reproducibilidad

El código utilizado para la preparación de datos, análisis exploratorio, ajuste de modelos, validación cruzada, comparación de métricas y generación de gráficos se encuentra disponible en el notebook asociado al trabajo.

- Base de datos utilizada: Encuesta CASEN 2024.
- Unidad de análisis: hogares, representados por la jefatura del hogar.
- Variable objetivo: `pobreza_ingresos`.
- Semilla utilizada: `SEED`.
- Principales librerías: `pandas`, `numpy`, `matplotlib`, `scikit-learn`.

El notebook permite reproducir el flujo completo del análisis, desde la limpieza inicial de la base hasta la comparación final de modelos y la obtención de la importancia de variables del Random Forest ajustado.

Enlace al GitHub con los códigos y la base de datos:

<https://github.com/franaravenag29/GRUP07--CASEN2024>

E. Coeficientes y odds ratios de la regresión logística

En este anexo se presentan los principales coeficientes y *odds ratios* obtenidos a partir de la regresión logística balanceada completa. Este modelo se utiliza como complemento interpretativo, ya que permite analizar la dirección de la asociación entre las variables predictoras y la probabilidad estimada de pobreza por ingresos.

En la regresión logística, un coeficiente positivo indica una asociación con mayor probabilidad estimada de pobreza, mientras que un coeficiente negativo indica una asociación con menor probabilidad estimada de pobreza, manteniendo constantes las demás variables del modelo. Al transformar los coeficientes mediante la función exponencial se obtienen los *odds ratios*. Valores mayores que 1 indican mayores chances estimadas de pobreza, mientras que valores menores que 1 indican menores chances estimadas.

Es importante considerar que las variables numéricas fueron estandarizadas mediante `StandardScaler`, por lo que sus coeficientes se interpretan ante aumentos de una desviación estándar y no en unidades originales. Además, las variables categóricas deben interpretarse siempre en comparación con su categoría de referencia.

Cuadro 9: Variables asociadas a mayor probabilidad estimada de pobreza

Variable	Coeficiente	Odds ratio
<code>ind_hacina_4</code>	0,727	2,069
<code>region_9</code>	0,691	1,995
<code>ind_hacina_3</code>	0,621	1,861
<code>nacido_fuera_chile_1</code>	0,615	1,850
<code>region_16</code>	0,571	1,771
<code>region_7</code>	0,522	1,685
<code>ind_estado_3</code>	0,520	1,682
<code>region_14</code>	0,449	1,567
<code>ind_hacina_2</code>	0,444	1,558
<code>ten_viv_f_2</code>	0,430	1,537

El Cuadro 9 muestra las variables o categorías con coeficientes positivos más relevantes. Estas se asocian con mayores chances estimadas de pobreza respecto de sus categorías de referencia. Entre ellas destacan

categorías vinculadas a hacinamiento, región, condición de nacimiento fuera de Chile, estado de la vivienda y tenencia de la vivienda.

Cuadro 10: Variables asociadas a menor probabilidad estimada de pobreza

Variable	Coeficiente	Odds ratio
tipohogar_5	-1,659	0,190
tasa_ocupados_hogar	-1,313	0,269
tipohogar_3	-1,215	0,297
activ_3.0	-1,212	0,297
activ_2.0	-1,141	0,320
contrato_1.0	-1,081	0,339
tipohogar_4	-1,045	0,352
tipohogar_6	-0,926	0,396
edad	-0,571	0,565
cotiza_1.0	-0,562	0,570
esc	-0,478	0,620
may60c_1	-0,368	0,692

El Cuadro 10 presenta variables o categorías con coeficientes negativos. Entre ellas destacan la tasa de ocupados del hogar, la escolaridad, la edad, la cotización previsional y algunas categorías de tipo de hogar, actividad y contrato. En particular, la variable `tasa\_ocupados\_hogar` presenta un *odds ratio* de 0,269, lo que indica que mayores niveles de ocupación dentro del hogar se asocian con menores chances estimadas de pobreza.

Estos resultados deben interpretarse como asociaciones predictivas y no como efectos causales. La regresión logística permite identificar variables que se relacionan con la probabilidad estimada de pobreza, pero no permite afirmar que dichas variables causen directamente la condición de pobreza por ingresos.